OpenAI 开发

OpenAI 接口文档

OpenAI 模型定价

- 基本概念
- 示例和详细解释
  - 示例一：简单对话
  - 输入token的累计和费用计算
- 理解和应用场景
- 总结

OpenAI 标准定价 vs 批量API

- 标准定价 vs 批量API定价
- 为什么价格不一样?
- 举个例子帮助理解
- 选择的考虑因素
- 总结

OpenAI 接口文档

官方文档：https://platform.openai.com/docs/api-reference/chat/create

Apifox中文文档：https://apifox.com/apidoc/shared-012b355c-5a9e-4b61-aeca-105d78dc51d5?pwd=jkai

OpenAI 模型定价

模型定价：https://openai.com/api/pricing/

基本概念

1. **Tokens**（标记）：

聚言Ai科技 JUKE AI SCI-TECH

- **定义**：在自然语言处理中，token是输入文本被分割成的小单元。一个token可以是一个单词、一个子词，甚至是一个字符。这取决于文本的具体分割方式。
- **举例**：在GPT模型中，"Hello, world!" 可能被分割成几个token，比如 ['Hello', ',', ' world', '!']。

1. **计费方式**：
   - **单位**：计费是按百万个输入token（1M input tokens）来计算的，即每处理一百万个输入token的费用为5美金。
   - **实际意义**：这意味着你使用GPT-4生成的文本越多，处理的输入token数量越大，费用也会随之增加。

示例和详细解释

示例一：简单对话

假设你使用GPT-4o进行一个简单对话，输入如下：

- **用户输入**： "What is the capital of France?"
  - **Token 数量**：这句话大概会被分成7个token。

```
"What" -> 1 token
"is" -> 1 token
"the" -> 1 token
"capital" -> 1 token
"of" -> 1 token
"France" -> 1 token
? -> 1 token
```

总共6个token。

- **模型生成的输出**： "The capital of France is Paris."
  - **Token 数量**：这句话大概会被分成7个token。

```
"The" -> 1 token
"capital" -> 1 token
"of" -> 1 token
"France" -> 1 token
"is" -> 1 token
"Paris" -> 1 token
. -> 1 token
```

总共7个token。

整个对话会消耗13个token（6个输入 + 7个输出）。

输入token的累计和费用计算

假设你连续进行了大量类似的对话，总共输入了100,000个token。那么：

1. **输入token数量**：100,000个input tokens
2. **对应费用**：(\frac{100,000 \text{ tokens}}{1,000,000 \text{ tokens}} \times 5 \text{ USD} = 0.5 \text{ USD})

理解和应用场景

1. **成本控制**：
    - **优化使用**：如果你对使用成本敏感，可以通过优化输入文本的长度和复杂度来控制费用。
    - **批量处理**：对于需要处理大量文本的应用，可以进行成本效益分析，确定最佳的使用策略。
1. **商业应用**：
    - **对话系统**：在客户服务、技术支持等应用中，可以根据对话量估算成本。
    - **内容生成**：对于需要生成大量内容的应用（如文章写作或编程助手），可以根据每百万个token的费用来预算项目成本。

总结

“US$5.00/1M input tokens”在GPT-4o中表示按百万个输入token来计费，每百万个输入token的计算费用为5美元。这种计费方式让用户能够更透明地了解和管理使用这些高级自然语言处理模型的成本。通过理解token的分割方式和具体的使用范例，用户可以更有效地计划和控制使用成本。GPT-4 可能提供两种不同的定价模式，分别为标准定价和批量API（Batch API）定价。让我们详细解释这些定价模式及其区别，以及为什么价格不同。

OpenAI 标准定价 vs 批量API

模型定价：https://openai.com/api/pricing/

Batch API：https://platform.openai.com/docs/guides/batch

标准定价 vs 批量API定价

1. **标准定价（US$5.00/1M input tokens）**：
   - **价格**：每处理一百万个输入token的费用是5美元。
   - **适用场景**：这种定价通常适用于常规使用，比如单次请求或小规模的交互。这适用于大多数开发者和小型应用。
1. **批量API定价（Batch API Pricing – US$2.50/1M input tokens）**：
   - **价格**：每处理一百万个输入token的费用是2.5美元，相当于标准定价的一半。
   - **适用场景**：这种较低价格通常适用于大量处理或批量操作场景。大型企业、需要处理大量数据的应用或者需要高频调用的场景更适合这种模式。

为什么价格不一样?

1. **经济规模效应**：
   - **批量折扣**：批量API定价反映了经济规模效应，即大量使用云计算资源可以分摊固定成本。因此，服务提供商通过较低的批量价格吸引大客户，用户通过批量使用享受折扣。
   - **资源利用优化**：批量请求可以优化资源分配，使提供商能更高效地利用计算资源，从而降低整体成本。
1. **使用模式不同**：
   - **标准请求**：标准定价适用于散布在较长时间内的单次请求或小规模的互动场景，这些场景下的调用可能更分散，资源利用率较低，需要更高的单价以覆盖运营和支持成本。
   - **批量请求**：批量API允许在短时间内处理大量请求，提升了资源利用率，同时减少了单次请求的管理和通信开销。这使服务提供商可以通过降低单价来吸引更多批量用户。

举个例子帮助理解

假设你有一个应用需要处理大量文本输入，如果你每月需要处理1000万个token，那么不同定价方案的成本计算如下：

1. **标准定价**：
   - **总费用**：$\frac{10,000,000 \text{ tokens}}{1,000,000 \text{ tokens}} \times 5 \text{ USD} = 50 \text{ USD}$
1. **批量API定价**：
   - **总费用**：$\frac{10,000,000 \text{ tokens}}{1,000,000 \text{ tokens}} \times 2.5 \text{ USD} = 25 \text{ USD}$

通过批量API，你可以在相同的使用量下显著节省费用。

选择的考虑因素

1. **使用量**：
    - **小规模**：对于不频繁或小规模调用的开发者，标准定价可能更加适合，因为他们不会达到批量使用的门槛。
    - **大规模**：对于频繁调用或大规模数据处理的场景，批量API定价更加经济实惠。
1. **预算和成本控制**：
    - **成本敏感**：如果你的项目预算紧张，选择批量API可以显著降低成本。
    - **方便性**：标准定价可能提供更灵活的调用方式，并且不需要批量请求的规划。
1. **技术实现**：
    - **批量处理**：需要考虑如何将调用合并成批量请求，这可能需要一些额外的开发工作。
    - **实时性**：标准定价可能更适合需要实时响应的应用，而批量处理适用于可以延迟处理的任务。

总结

两个不同的定价方案主要区别在于使用模式和规模的不同。标准定价（US$5.00/1M input tokens）适用于小规模和分散调用，而批量API定价（US$2.50/1M input tokens）更适合大规模、批量处理的场景。价格差异反映了经济规模效应和资源利用的优化，当选择哪种定价方式时，需要根据具体的使用场景和需求进行考虑。

聚客AI科技 JUKE AI SCI-TECH